

Quanthaton TuQanes

Luis Zumbado

1. Notación y formulación del problema

1.1. Conjunto de datos

Sea

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$$

el conjunto de datos de casos completos del conjunto de referencia *Water Potability*, donde

$$N = 2011.$$

Para la observación i ,

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ x_{i3} \\ x_{i4} \end{bmatrix} \in \mathbb{R}^4$$

es la representación fisicoquímica de cuatro dimensiones, mientras que

$$y_i \in \{0, 1\}$$

es la etiqueta de clase proporcionada por el conjunto de referencia.

Las etiquetas se definen como

$$y_i = \begin{cases} 0, & \text{clase no potable del conjunto de referencia,} \\ 1, & \text{clase potable del conjunto de referencia.} \end{cases}$$

La etiqueta y_i se trata estrictamente como la variable objetivo proporcionada por el conjunto de referencia. No se interpreta como una certificación regulatoria de la calidad del agua para consumo humano.

1.2. Variables fisicoquímicas

El vector de entrada se ordena de la siguiente manera:

$$\mathbf{x}_i = \begin{bmatrix} \text{pH}_i \\ H_i \\ S_i \\ C_i \end{bmatrix},$$

donde los símbolos se definen en la Tabla 1.

Cuadro 1: Variables fisicoquímicas utilizadas por los modelos clásicos y cuánticos.

Índice	Símbolo	Variable	Significado físico
1	pH	pH	Carácter ácido–base de la muestra de agua.
2	H	Dureza	Dureza total, expresada en mg L^{-1} de iones Calcio y Magnesio.
3	S	Sulfato	Concentración de sulfato, expresada en mg L^{-1} .
4	C	Conductividad	Conductividad eléctrica, expresada en $\mu\text{S cm}^{-1}$.

La asignación correspondiente de los cúbits se mantiene fija como

$$q_0 \longleftrightarrow \text{pH}, \quad q_1 \longleftrightarrow H, \quad q_2 \longleftrightarrow S, \quad q_3 \longleftrightarrow C.$$

1.3. Partición fija de los datos

El conjunto de datos de casos completos se dividió en dos subconjuntos disjuntos:

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}},$$

con

$$\mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \emptyset.$$

Sus tamaños son

$$N_{\text{train}} = 1608, \quad N_{\text{test}} = 403.$$

La partición se estratificó con respecto a y , utilizando la semilla aleatoria fija

$$s_0 = 4524.$$

La partición de prueba permaneció aislada durante la construcción del mapa de características, la especificación de hiperparámetros, la auditoría de los circuitos y la selección multisevilla de los modelos.

1.4. Subconjuntos cuánticos anidados

Para cada semilla de muestreo s , se extrajeron tres subconjuntos balanceados y anidados exclusivamente a partir de $\mathcal{D}_{\text{train}}$:

$$\mathcal{S}_{16}^{(s)} \subset \mathcal{S}_{32}^{(s)} \subset \mathcal{S}_{64}^{(s)}.$$

Sus composiciones de clase fueron

$$\left| \mathcal{S}_{16}^{(s)} \right| = 8 + 8,$$

$$\left| \mathcal{S}_{32}^{(s)} \right| = 16 + 16,$$

y

$$\left| \mathcal{S}_{64}^{(s)} \right| = 32 + 32,$$

donde el primer y el segundo término representan, respectivamente, el número de observaciones con $y = 0$ y con $y = 1$.

Se utilizaron veinte semillas de muestreo:

$$s \in \{4524, 4525, \dots, 4543\}.$$

1.5. Estandarización por pliegue

Sean $\mu_j^{(r)}$ y $\sigma_j^{(r)}$ la media y la desviación estándar de la variable j , calculadas exclusivamente a partir de la porción de entrenamiento del pliegue r de la validación cruzada.

El valor estandarizado se define como

$$z_{ij}^{(r)} = \frac{x_{ij} - \mu_j^{(r)}}{\sigma_j^{(r)}}.$$

En esta expresión:

x_{ij} valor observado de la variable j para la muestra i ;

$\mu_j^{(r)}$ media de la variable j calculada en el pliegue de entrenamiento;

$\sigma_j^{(r)}$ desviación estándar de la variable j calculada en el pliegue de entrenamiento;

$z_{ij}^{(r)}$ valor estandarizado utilizado en la partición r .

Los estadísticos $\mu_j^{(r)}$ y $\sigma_j^{(r)}$ nunca se estimaron utilizando observaciones pertenecientes al pliegue de validación.

1.6. Codificación cuántica mediante ángulos

Cada valor estandarizado se transformó en un ángulo de rotación acotado:

$$\theta_{ij}^{(r)} = \frac{\pi}{2} \tanh \left(z_{ij}^{(r)} \right).$$

Por lo tanto,

$$-\frac{\pi}{2} < \theta_{ij}^{(r)} < \frac{\pi}{2}.$$

Los símbolos representan:

$\theta_{ij}^{(r)}$ ángulo asignado al cúbit j para la muestra i ;

$\tanh(\cdot)$ transformación no lineal acotada;

$\pi/2$ valor absoluto máximo del ángulo utilizado en la codificación.

Esta transformación es monótona y evita que los valores estandarizados no acotados produzcan ángulos de rotación sin restricciones.

2. Máquina de vectores de soporte clásica

2.1. Convención de etiquetas binarias

La etiqueta del conjunto de referencia satisface

$$y_i \in \{0, 1\}.$$

Para la máquina de vectores de soporte, se transforma en la etiqueta simétrica

$$\tilde{y}_i = 2y_i - 1,$$

de modo que

$$\tilde{y}_i \in \{-1, +1\}.$$

Explícitamente,

$$\tilde{y}_i = \begin{cases} -1, & y_i = 0, \\ +1, & y_i = 1. \end{cases}$$

Aquí,

y_i etiqueta original del conjunto de referencia;

$\tilde{y}_i$ etiqueta utilizada en el problema de optimización de la SVM.

2.2. Hiperplano lineal de separación

Sea

$$\phi : \mathbb{R}^4 \longrightarrow \mathcal{H}$$

una transformación desde el espacio de entrada estandarizado hacia un espacio de características $\mathcal{H}$.

El hiperplano de separación se define mediante

$$f(\mathbf{z}) = \mathbf{w}^\top \phi(\mathbf{z}) + b,$$

donde

$\mathbf{z}$ vector fisicoquímico estandarizado;

$\phi(\mathbf{z})$ representación de $\mathbf{z}$ en el espacio de características;

$\mathbf{w}$ vector normal al hiperplano de separación;

b término independiente;

$f(\mathbf{z})$ valor de decisión con signo.

La clase predicha es

$$\hat{y} = \begin{cases} 1, & f(\mathbf{z}) \geq 0, \\ 0, & f(\mathbf{z}) < 0. \end{cases}$$

2.3. Margen geométrico

La distancia con signo desde $\phi(\mathbf{z}_i)$ hasta el hiperplano es proporcional a

$$\frac{\tilde{y}_i [\mathbf{w}^\top \phi(\mathbf{z}_i) + b]}{\|\mathbf{w}\|_2}.$$

La distancia entre los dos hiperplanos canónicos del margen es

$$\mathcal{M} = \frac{2}{\|\mathbf{w}\|_2}.$$

Por lo tanto, maximizar el margen equivale a minimizar

$$\frac{1}{2} \|\mathbf{w}\|_2^2.$$

2.4. Problema primal de margen suave

Debido a que las clases no son perfectamente separables, se introducen variables de holgura no negativas:

$$\xi_i \geq 0.$$

La SVM de margen suave resuelve

$$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n \xi_i$$

sujeto a

$$\tilde{y}_i [\mathbf{w}^\top \phi(\mathbf{z}_i) + b] \geq 1 - \xi_i, \quad i = 1, \dots, n,$$

y

$$\xi_i \geq 0.$$

Los símbolos representan

n número de observaciones en el pliegue de entrenamiento;

ξ_i violación del margen asociada con la observación i ;

C parámetro de regularización;

$\|\mathbf{w}\|_2^2$ penalización de la complejidad del modelo;

$\sum_i \xi_i$ penalización total por violaciones del margen.

2.5. Interpretación del parámetro de regularización

La constante $C > 0$ controla el equilibrio entre la amplitud del margen y las violaciones durante el entrenamiento.

Para valores grandes de C ,

$$C \uparrow \implies \text{mayor penalización de los errores de entrenamiento.}$$

Para valores pequeños de C ,

$$C \downarrow \implies \text{margen más amplio y mayor regularización.}$$

El experimento principal utilizó el valor fijo

$$C = 1.$$

No se realizó ajuste de hiperparámetros dentro de la comparación principal entre los modelos cuántico y clásico.

2.6. Formulación lagrangiana

Sea $\alpha_i \geq 0$ el multiplicador de Lagrange asociado con la restricción del margen y sea $\mu_i \geq 0$ el multiplicador asociado con la condición $\xi_i \geq 0$.

El lagrangiano primal es

$$\begin{aligned}\mathcal{L} = & \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n \xi_i \\ & - \sum_{i=1}^n \alpha_i \{ \tilde{y}_i [\mathbf{w}^\top \phi(\mathbf{z}_i) + b] - 1 + \xi_i \} \\ & - \sum_{i=1}^n \mu_i \xi_i.\end{aligned}$$

La condición de estacionariedad con respecto a $\mathbf{w}$ proporciona

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^n \alpha_i \tilde{y}_i \phi(\mathbf{z}_i) = 0.$$

Por lo tanto,

$$\mathbf{w} = \sum_{i=1}^n \alpha_i \tilde{y}_i \phi(\mathbf{z}_i).$$

La condición de estacionariedad con respecto a b proporciona

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n \alpha_i \tilde{y}_i = 0,$$

y, por consiguiente,

$$\sum_{i=1}^n \alpha_i \tilde{y}_i = 0.$$

2.7. Problema dual de optimización

La sustitución de las condiciones anteriores en el lagrangiano produce el problema dual

$$\max_{\alpha} \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \tilde{y}_i \tilde{y}_j K(\mathbf{z}_i, \mathbf{z}_j)$$

sujeto a

$$0 \leq \alpha_i \leq C, \quad i = 1, \dots, n,$$

y

$$\sum_{i=1}^n \alpha_i \tilde{y}_i = 0.$$

El kernel se define como

$$K(\mathbf{z}_i, \mathbf{z}_j) = \langle \phi(\mathbf{z}_i), \phi(\mathbf{z}_j) \rangle_{\mathcal{H}}.$$

No es necesario calcular explícitamente las coordenadas de $\phi(\mathbf{z})$. Únicamente se requieren los valores del kernel entre pares de observaciones.

2.8. Vectores de soporte

Una observación es un vector de soporte cuando

$$\alpha_i > 0.$$

Las observaciones que satisfacen

$$\alpha_i = 0$$

no contribuyen directamente a la función de decisión final.

El conjunto de vectores de soporte es

$$\mathcal{I}_{\text{SV}} = \{i : \alpha_i > 0\}.$$

2.9. Función de decisión basada en el kernel

La representación dual de la función de decisión es

$$f(\mathbf{z}) = \sum_{i \in \mathcal{I}_{\text{SV}}} \alpha_i \tilde{y}_i K(\mathbf{z}_i, \mathbf{z}) + b.$$

La etiqueta predicha por la SVM es

$$\hat{\tilde{y}} = \text{sign} [f(\mathbf{z})].$$

Esta se convierte a la convención del conjunto de referencia mediante

$$\hat{y} = \frac{\hat{\tilde{y}} + 1}{2}.$$

2.10. Kernel de función de base radial

El modelo clásico de referencia utilizó el kernel gaussiano de función de base radial:

$$K_{\text{RBF}}(\mathbf{z}_i, \mathbf{z}_j) = \exp \left[-\gamma \|\mathbf{z}_i - \mathbf{z}_j\|_2^2 \right].$$

La distancia euclídea al cuadrado es

$$\|\mathbf{z}_i - \mathbf{z}_j\|_2^2 = \sum_{k=1}^d (z_{ik} - z_{jk})^2,$$

con

$$d = 4.$$

Por lo tanto,

$$K_{\text{RBF}}(\mathbf{z}_i, \mathbf{z}_j) \in (0, 1].$$

Para observaciones idénticas,

$$\mathbf{z}_i = \mathbf{z}_j \implies K_{\text{RBF}}(\mathbf{z}_i, \mathbf{z}_j) = 1.$$

Para observaciones cada vez más distantes,

$$\|\mathbf{z}_i - \mathbf{z}_j\|_2 \longrightarrow \infty$$

implica

$$K_{\text{RBF}}(\mathbf{z}_i, \mathbf{z}_j) \longrightarrow 0.$$

2.11. Interpretación del parámetro γ

El parámetro $\gamma > 0$ determina la escala espacial del kernel RBF.
Para valores grandes de γ ,

$$\gamma \uparrow \implies \text{disminución rápida de la similitud.}$$

La frontera de decisión resultante puede volverse altamente local.
Para valores pequeños de γ ,

$$\gamma \downarrow \implies \text{disminución lenta de la similitud.}$$

La frontera de decisión resultante se vuelve más suave.
El modelo clásico de referencia utilizó

$$\gamma = \text{scale}.$$

Según la convención de *scikit-learn*,

$$\gamma_{\text{scale}} = \frac{1}{d \text{Var}(\mathbf{Z}_{\text{train}})},$$

donde

d número de variables de entrada;

$\mathbf{Z}_{\text{train}}$ matriz estandarizada del pliegue de entrenamiento;

$\text{Var}(\mathbf{Z}_{\text{train}})$ varianza calculada a partir de la matriz de entrenamiento.

Debido a que las cuatro variables se estandarizan dentro de cada pliegue de entrenamiento,

$$\text{Var}(\mathbf{Z}_{\text{train}}) \approx 1,$$

y, por consiguiente,

$$\gamma_{\text{scale}} \approx \frac{1}{4}.$$

2.12. Especificación clásica fija

El modelo clásico de comparación fue

`SVC(K = KRBF, C = 1, γ = scale, class_weight = None)`

con las siguientes restricciones:

1. los modelos clásico y cuántico utilizaron el mismo subconjunto;
2. se utilizaron las mismas particiones de validación cruzada;
3. el escalador se ajustó independientemente dentro de cada pliegue de entrenamiento;
4. ningún modelo se ajustó utilizando las observaciones de validación;
5. la partición de prueba aislada no se utilizó para la selección de modelos.

3. Kernel cuántico de fidelidad

3.1. Registro cuántico

El modelo cuántico utiliza

$$n_q = 4$$

cúbits.

El espacio de Hilbert asociado es

$$\mathcal{H}_Q = (\mathbb{C}^2)^{\otimes 4},$$

con dimensión

$$\dim(\mathcal{H}_Q) = 2^4 = 16.$$

El estado inicial es

$$|0\rangle^{\otimes 4} = |0000\rangle.$$

Aquí,

n_q número de cúbits;

$\mathcal{H}_Q$ espacio de Hilbert de cuatro cúbits;

$|0000\rangle$ estado inicial de la base computacional.

3.2. Mapa cuántico de características

Sea

$$U_{\phi}(\boldsymbol{\theta})$$

un circuito unitario parametrizado, donde

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix}.$$

La representación cuántica de la observación i es

$$|\phi_i\rangle = |\phi(\mathbf{x}_i)\rangle = U_{\phi}(\boldsymbol{\theta}_i) |0000\rangle.$$

El vector de ángulos se obtiene a partir de las variables fisicoquímicas estandarizadas:

$$\boldsymbol{\theta}_i = \frac{\pi}{2} \tanh(\mathbf{z}_i),$$

donde la tangente hiperbólica se aplica componente a componente.

Los símbolos representan

U_{ϕ} circuito del mapa cuántico de características;

$\boldsymbol{\theta}_i$ vector de ángulos codificados de la observación i ;

$|\phi_i\rangle$ estado cuántico normalizado que representa la observación i .

Debido a que U_{ϕ} es unitario,

$$\langle \phi_i | \phi_i \rangle = 1.$$

3.3. Solapamiento entre estados

Para dos observaciones i y j , su solapamiento cuántico complejo es

$$A_{ij} = \langle \phi_j | \phi_i \rangle.$$

A partir de la definición del circuito,

$$A_{ij} = \langle 0000 | U_{\phi}^{\dagger}(\boldsymbol{\theta}_j) U_{\phi}(\boldsymbol{\theta}_i) | 0000 \rangle.$$

La cantidad A_{ij} es, en general, compleja y satisface

$$|A_{ij}| \leq 1.$$

3.4. Kernel de fidelidad

El kernel cuántico de fidelidad se define como

$$K_Q(\mathbf{x}_i, \mathbf{x}_j) = |\langle \phi_j | \phi_i \rangle|^2.$$

Equivalentemente,

$$K_{Q,ij} = |A_{ij}|^2.$$

Por lo tanto,

$$0 \leq K_{Q,ij} \leq 1.$$

Para estados idénticos,

$$|\phi_i\rangle = |\phi_j\rangle,$$

y, en consecuencia,

$$K_{Q,ij} = 1.$$

Para estados ortogonales,

$$\langle \phi_j | \phi_i \rangle = 0,$$

y, por lo tanto,

$$K_{Q,ij} = 0.$$

3.5. Circuito de solapamiento

Se define el estado de solapamiento como

$$|\chi_{ij}\rangle = U_\phi^\dagger(\boldsymbol{\theta}_j) U_\phi(\boldsymbol{\theta}_i) |0000\rangle.$$

La amplitud del estado de base compuesto únicamente por ceros es

$$\langle 0000 | \chi_{ij} \rangle = \langle 0000 | U_\phi^\dagger(\boldsymbol{\theta}_j) U_\phi(\boldsymbol{\theta}_i) | 0000 \rangle.$$

De acuerdo con la definición de los estados codificados,

$$\langle 0000 | \chi_{ij} \rangle = \langle \phi_j | \phi_i \rangle.$$

Por consiguiente, la probabilidad de medir la cadena de bits 0000 es

$$\begin{aligned}
P_{ij}(0000) &= |\langle 0000 | \chi_{ij} \rangle|^2 \\
&= |\langle \phi_j | \phi_i \rangle|^2 \\
&= K_{Q,ij}.
\end{aligned}$$

Por lo tanto,

$$\boxed{K_{Q,ij} = P_{ij}(0000)}$$

para el circuito ideal de solapamiento.

3.6. Formulación mediante un proyector de medición

Sea

$$\Pi_0 = |0000\rangle\langle 0000|$$

el proyector sobre el estado computacional compuesto únicamente por ceros. Entonces,

$$K_{Q,ij} = \langle \chi_{ij} | \Pi_0 | \chi_{ij} \rangle.$$

Equivalentemente,

$$K_{Q,ij} = \text{Tr} [\Pi_0 | \chi_{ij} \rangle \langle \chi_{ij} |].$$

3.7. Representación mediante matrices de densidad

Se define la matriz de densidad del estado puro como

$$\rho_i = |\phi_i\rangle\langle \phi_i|.$$

El kernel de fidelidad puede escribirse como

$$K_{Q,ij} = \text{Tr} (\rho_i \rho_j).$$

En efecto,

$$\begin{aligned}
\text{Tr} (\rho_i \rho_j) &= \text{Tr} [|\phi_i\rangle\langle \phi_i | \phi_j\rangle\langle \phi_j|] \\
&= \langle \phi_i | \phi_j \rangle \langle \phi_j | \phi_i \rangle \\
&= |\langle \phi_j | \phi_i \rangle|^2.
\end{aligned}$$

3.8. Matriz de Gram cuántica

Para un conjunto de n observaciones, la matriz de Gram cuántica es

$$\mathbf{K}_Q = \begin{bmatrix} K_{Q,11} & K_{Q,12} & \cdots & K_{Q,1n} \\ K_{Q,21} & K_{Q,22} & \cdots & K_{Q,2n} \\ \vdots & \vdots & \ddots & \vdots \\ K_{Q,n1} & K_{Q,n2} & \cdots & K_{Q,nn} \end{bmatrix}.$$

Sus elementos son

$$(\mathbf{K}_Q)_{ij} = K_{Q,ij}.$$

3.9. Simetría

Debido a que

$$\langle \phi_i | \phi_j \rangle = \langle \phi_j | \phi_i \rangle^*,$$

se cumple que

$$K_{Q,ij} = K_{Q,ji}.$$

Por lo tanto,

$$\mathbf{K}_Q = \mathbf{K}_Q^\top.$$

3.10. Diagonal unitaria

Para todo estado codificado normalizado,

$$K_{Q,ii} = |\langle \phi_i | \phi_i \rangle|^2 = 1.$$

Por lo tanto,

$$\text{diag}(\mathbf{K}_Q) = \mathbf{1}.$$

3.11. Semidefinitud positiva

Sea

$$\mathbf{c} = \begin{bmatrix} c_1 & c_2 & \cdots & c_n \end{bmatrix}^\top \in \mathbb{R}^n.$$

Entonces,

$$\begin{aligned}\mathbf{c}^\top \mathbf{K}_Q \mathbf{c} &= \sum_{i=1}^n \sum_{j=1}^n c_i c_j \operatorname{Tr}(\rho_i \rho_j) \\ &= \operatorname{Tr} \left[\left(\sum_{i=1}^n c_i \rho_i \right)^2 \right].\end{aligned}$$

Utilizando la norma de Hilbert–Schmidt,

$$\|A\|_{\text{HS}}^2 = \operatorname{Tr}(A^\dagger A),$$

y considerando que cada ρ_i es hermítica,

$$\mathbf{c}^\top \mathbf{K}_Q \mathbf{c} = \left\| \sum_{i=1}^n c_i \rho_i \right\|_{\text{HS}}^2 \geq 0.$$

Por lo tanto,

$$\boxed{\mathbf{K}_Q \succeq 0}$$

y la matriz exacta de fidelidad cuántica es una matriz kernel válida.

3.12. Evaluaciones únicas del kernel

Una matriz kernel simétrica de tamaño $n \times n$ contiene

$$\frac{n(n+1)}{2}$$

elementos únicos cuando se incluye la diagonal.

El número de elementos únicos fuera de la diagonal es

$$\frac{n(n-1)}{2}.$$

Para los tres tamaños de los subconjuntos cuánticos,

n	Elementos únicos	Elementos fuera de la diagonal
16	136	120
32	528	496
64	2080	2016

Este escalamiento cuadrático justifica el uso de tamaños restringidos para los conjuntos de entrenamiento cuántico.

3.13. Matrices kernel de entrenamiento y validación

Sea n_{tr} el número de observaciones del pliegue de entrenamiento y n_{val} el número de observaciones del pliegue de validación.

La matriz de Gram de entrenamiento es

$$\mathbf{K}_{\text{tr}} \in \mathbb{R}^{n_{\text{tr}} \times n_{\text{tr}}},$$

con elementos

$$(\mathbf{K}_{\text{tr}})_{ij} = K_Q(\mathbf{x}_i^{\text{tr}}, \mathbf{x}_j^{\text{tr}}).$$

La matriz kernel entre validación y entrenamiento es

$$\mathbf{K}_{\text{val, tr}} \in \mathbb{R}^{n_{\text{val}} \times n_{\text{tr}}},$$

con elementos

$$(\mathbf{K}_{\text{val, tr}})_{ij} = K_Q(\mathbf{x}_i^{\text{val}}, \mathbf{x}_j^{\text{tr}}).$$

La SVM se ajusta utilizando

$$\mathbf{K}_{\text{tr}},$$

mientras que las predicciones se obtienen utilizando

$$\mathbf{K}_{\text{val, tr}}.$$

3.14. SVM con kernel cuántico

El problema dual de la SVM conserva la forma

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \tilde{y}_i \tilde{y}_j K_{Q, ij},$$

sujeeto a

$$0 \leq \alpha_i \leq C$$

y

$$\sum_{i=1}^n \alpha_i \tilde{y}_i = 0.$$

La función de decisión resultante es

$$f_Q(\mathbf{x}) = \sum_{i \in \mathcal{I}_{SV}} \alpha_i \tilde{y}_i K_Q(\mathbf{x}_i, \mathbf{x}) + b.$$

Los modelos cuánticos principales utilizaron

$$C = 1,$$

sin ajuste de hiperparámetros del kernel cuántico.

3.15. Correspondencia entre los modelos clásico y cuántico

Los clasificadores clásico y cuántico presentan la misma estructura de optimización. Para el modelo clásico,

$$K(\mathbf{x}_i, \mathbf{x}_j) = K_{\text{RBF}}(\mathbf{z}_i, \mathbf{z}_j).$$

Para el modelo cuántico,

$$K(\mathbf{x}_i, \mathbf{x}_j) = K_Q(\mathbf{x}_i, \mathbf{x}_j).$$

Por lo tanto, la diferencia entre ambos clasificadores se encuentra en la geometría inducida:

mismo optimizador SVM + geometría kernel diferente
--

El circuito cuántico no optimiza los coeficientes de los vectores de soporte. Su función consiste únicamente en construir los elementos de la matriz kernel.

4. Mapas cuánticos de características

4.1. Operadores elementales

Sean

$$X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad Y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix}, \quad Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

los operadores de Pauli.

Las rotaciones de un cúbit utilizadas en este trabajo son

$$R_Y(\alpha) = \exp\left(-\frac{i\alpha}{2}Y\right)$$

y

$$R_Z(\alpha) = \exp\left(-\frac{i\alpha}{2}Z\right).$$

Sus representaciones matriciales son

$$R_Y(\alpha) = \begin{bmatrix} \cos(\alpha/2) & -\sin(\alpha/2) \\ \sin(\alpha/2) & \cos(\alpha/2) \end{bmatrix}$$

y

$$R_Z(\alpha) = \begin{bmatrix} e^{-i\alpha/2} & 0 \\ 0 & e^{i\alpha/2} \end{bmatrix}.$$

La rotación ZZ de dos cúbits se define como

$$R_{ZZ}^{(a,b)}(\beta) = \exp\left(-\frac{i\beta}{2}Z_a Z_b\right),$$

donde a y b representan los cúbits que interactúan.

De manera análoga, la interacción YY se define como

$$R_{YY}^{(a,b)}(\beta) = \exp\left(-\frac{i\beta}{2}Y_a Y_b\right).$$

Los símbolos representan

α ángulo de rotación de un cúbit;

β ángulo de interacción entre dos cúbits;

$Z_a Z_b$ operador producto tensorial que actúa sobre los cúbits a y b ;

$Y_a Y_b$ interacción de Pauli entre dos cúbits.

4.2. Grafos de interacción

El grafo lineal genérico de interacción es

$$\mathcal{E}_{\text{lineal}} = \{(0, 1), (1, 2), (2, 3)\}.$$

El grafo propuesto, informado por el dominio, es

$$\mathcal{E}_{\text{dominio}} = \{(0, 1), (1, 3), (2, 3)\}.$$

Utilizando la asignación fija de cúbits,

$$q_0 \leftrightarrow \text{pH}, \quad q_1 \leftrightarrow H, \quad q_2 \leftrightarrow S, \quad q_3 \leftrightarrow C,$$

las conexiones informadas por el dominio representan

$$(0, 1) \leftrightarrow \text{pH} \times H,$$

$$(1, 3) \leftrightarrow H \times C,$$

y

$$(2, 3) \leftrightarrow S \times C.$$

4.3. Control separable

El control separable aplica dos rotaciones locales a cada cúbit:

$$U_{\text{sep}}(\boldsymbol{\theta}) = \prod_{j=0}^3 R_Z^{(j)}(\theta_j) R_Y^{(j)}(\theta_j).$$

El orden de aplicación en el circuito es

$$R_Y(\theta_j) \longrightarrow R_Z(\theta_j).$$

El estado codificado es

$$|\phi_{\text{sep}}(\boldsymbol{\theta})\rangle = U_{\text{sep}}(\boldsymbol{\theta})|0000\rangle.$$

Debido a que todos los operadores actúan localmente,

$$|\phi_{\text{sep}}(\boldsymbol{\theta})\rangle = \bigotimes_{j=0}^3 [R_Z(\theta_j) R_Y(\theta_j) |0\rangle].$$

Por lo tanto, el estado es separable y no contiene correlaciones cuánticas entre variables diferentes.

Su kernel de fidelidad se factoriza como

$$K_{\text{sep}}(\boldsymbol{\theta}_i, \boldsymbol{\theta}_j) = \prod_{k=0}^3 |\langle \phi_k(\theta_{jk}) | \phi_k(\theta_{ik}) \rangle|^2.$$

El mapa separable funciona como control negativo para evaluar la contribución de las interacciones entre múltiples cúbits.

4.4. Mapa de características ZZ lineal

El mapa ZZ lineal utiliza una codificación local de fase dependiente de Z e interacciones ZZ por pares sobre el grafo $\mathcal{E}_{\text{lineal}}$.

Su forma abstracta es

$$U_{ZZ}(\boldsymbol{\theta}) = U_{ZZ,\text{int}}(\boldsymbol{\theta})U_{Z,\text{loc}}(\boldsymbol{\theta})H^{\otimes 4},$$

donde

$$U_{Z,\text{loc}}(\boldsymbol{\theta}) = \prod_{j=0}^3 \exp\left(-\frac{i}{2}\theta_j Z_j\right)$$

y

$$U_{ZZ,\text{int}}(\boldsymbol{\theta}) = \prod_{(a,b) \in \mathcal{E}_{\text{lineal}}} \exp\left[-\frac{i}{2}\theta_a \theta_b Z_a Z_b\right].$$

El estado codificado correspondiente es

$$|\phi_{ZZ}(\boldsymbol{\theta})\rangle = U_{ZZ}(\boldsymbol{\theta})|0000\rangle.$$

Los ángulos de interacción son

$$\beta_{ab} = \theta_a \theta_b.$$

Por consiguiente, el circuito contiene explícitamente los productos

$$\theta_0 \theta_1, \quad \theta_1 \theta_2, \quad \theta_2 \theta_3.$$

La implementación en Qiskit utilizó

$$\text{reps} = 1, \quad \text{entanglement} = \text{linear},$$

y la función personalizada de datos

$$g(\theta_a, \theta_b) = \theta_a \theta_b.$$

Las descomposiciones en compuertas de fase utilizadas por el entorno de desarrollo son equivalentes a la representación mediante evolución de Pauli, salvo por posibles fases globales sin relevancia física.

4.5. Mapa de características de Pauli $Z + YY$

El mapa de Pauli combina términos locales Z con interacciones YY por pares. Su forma abstracta es

$$U_{ZYY}(\boldsymbol{\theta}) = U_{YY,\text{int}}(\boldsymbol{\theta})U_{Z,\text{loc}}(\boldsymbol{\theta})H^{\otimes 4},$$

donde

$$U_{YY,\text{int}}(\boldsymbol{\theta}) = \prod_{(a,b) \in \mathcal{E}_{\text{lineal}}} \exp \left[-\frac{i}{2} \theta_a \theta_b Y_a Y_b \right].$$

El estado codificado es

$$|\phi_{ZYY}(\boldsymbol{\theta})\rangle = U_{ZYY}(\boldsymbol{\theta})|0000\rangle.$$

Los términos de interacción son nuevamente

$$\theta_0 \theta_1, \quad \theta_1 \theta_2, \quad \theta_2 \theta_3,$$

pero el generador es ahora $Y_a Y_b$, en lugar de $Z_a Z_b$.

La implementación utilizó

$$\text{paulis} = [\text{Z}, \text{YY}],$$

$$\text{reps} = 1, \quad \text{entanglement} = \text{linear}.$$

La evolución YY se implementa mediante cambios de base y operaciones de dos cúbits generadas por el entorno de desarrollo utilizado.

4.6. Mapa disperso informado por el dominio

El mapa personalizado propuesto consta de una capa de codificación local, seguida por una capa dispersa de interacciones ZZ .

Se define

$$U_{\text{loc}}(\boldsymbol{\theta}) = \prod_{j=0}^3 R_Z^{(j)}(\theta_j) R_Y^{(j)}(\theta_j).$$

La capa de interacción se define como

$$U_{\text{dominio}}(\boldsymbol{\theta}) = \prod_{(a,b) \in \mathcal{E}_{\text{dominio}}} R_{ZZ}^{(a,b)}(\theta_a \theta_b).$$

El mapa completo de características es

$$U_{\text{custom}}(\boldsymbol{\theta}) = U_{\text{dominio}}(\boldsymbol{\theta})U_{\text{loc}}(\boldsymbol{\theta})$$

y el estado codificado es

$$|\phi_{\text{custom}}(\boldsymbol{\theta})\rangle = U_{\text{custom}}(\boldsymbol{\theta})|0000\rangle.$$

Escrito explícitamente,

$$U_{\text{custom}}(\boldsymbol{\theta}) = R_{ZZ}^{(2,3)}(\theta_2\theta_3)R_{ZZ}^{(1,3)}(\theta_1\theta_3)R_{ZZ}^{(0,1)}(\theta_0\theta_1) \\ \times \prod_{j=0}^3 R_Z^{(j)}(\theta_j)R_Y^{(j)}(\theta_j).$$

Todos los generadores ZZ conmutan:

$$[Z_a Z_b, Z_c Z_d] = 0.$$

Por consiguiente, la capa matemática de interacción es independiente del orden de sus tres compuertas R_{ZZ} .

4.7. Interpretación de las interacciones personalizadas

El primer ángulo de interacción es

$$\beta_{01} = \theta_{\text{pH}}\theta_H.$$

Este término codifica una dependencia conjunta entre el carácter ácido–base y la dureza.

El segundo ángulo de interacción es

$$\beta_{13} = \theta_H\theta_C.$$

Este término codifica una dependencia conjunta entre la dureza y la conductividad eléctrica.

El tercer ángulo de interacción es

$$\beta_{23} = \theta_S\theta_C.$$

Este término codifica una dependencia conjunta entre la concentración de sulfato y la conductividad eléctrica.

Estos términos constituyen una topología dispersa informada por el dominio. No representan un modelo mecanístico completo de la química acuosa.

4.8. Entrelazamiento dependiente de la entrada

La presencia de una compuerta R_{ZZ} no garantiza un entrelazamiento distinto de cero para todas las observaciones.

Por ejemplo,

$$\theta_a \theta_b = 0$$

implica

$$R_{ZZ}(\theta_a \theta_b) = I.$$

De manera más general, el estado generado puede permanecer separable para determinados valores de entrada o estados locales.

Por lo tanto, la afirmación correcta es

el mapa personalizado permite entrelazamiento dependiente de la entrada,
en lugar de

el mapa personalizado entrelaza todas las muestras codificadas.

4.9. Kernel inducido por cada mapa

Para cada mapa de características m , se define

$$m \in \{\text{sep}, \text{ZZ}, \text{ZYY}, \text{custom}\}.$$

Su kernel de fidelidad es

$$K_m(\mathbf{x}_i, \mathbf{x}_j) = \left| \langle 0000 | U_m^\dagger(\boldsymbol{\theta}_j) U_m(\boldsymbol{\theta}_i) | 0000 \rangle \right|^2.$$

Los cuatro mapas utilizan los mismos valores de

$$\mathbf{x}_i, \quad \mathbf{z}_i, \quad \boldsymbol{\theta}_i, \quad C = 1,$$

pero inducen matrices de Gram diferentes:

$$\mathbf{K}_{\text{sep}}, \quad \mathbf{K}_{\text{ZZ}}, \quad \mathbf{K}_{\text{ZYY}}, \quad \mathbf{K}_{\text{custom}}.$$

Por lo tanto, cualquier diferencia predictiva surge de la geometría inducida por el mapa de características y no de un optimizador SVM diferente.

Cuadro 2: Estructura lógica de los cuatro mapas cuánticos de características.

Mapa	Codificación local	Interacción	Grafo	Términos 2Q
Separable	R_Y, R_Z	Ninguna	Ninguno	0
ZZ lineal	Fase Z	ZZ	Lineal	3
Pauli $Z + YY$	Fase Z	YY	Lineal	3
Personalizado	R_Y, R_Z	ZZ	Informado por el dominio	3

4.10. Comparación lógica

El número lógico de interacciones no necesariamente coincide con el número final de compuertas físicas. El costo debemos de estimarlo antes de meterlo a nexxus después de compilar el circuito al conjunto nativo de compuertas.

4.11. Hipótesis de diseño

La hipótesis principal del mapa de características fue

$$\text{mediana}_s \left[\text{BA}_{\text{custom}}^{(s)} - \text{BA}_{\text{sep}}^{(s)} \right] > 0.$$

La comparación con el mapa ZZ genérico evaluó si la topología dispersa informada por el dominio podía mejorar la geometría inducida sin aumentar el costo compilado de recursos de dos cúbits.

5. El famoso experimento

5.1. Cuál fue el objetivo?

Evaluamos si la geometría inducida por un featuremap de características podía mejorar la clasificación con respecto a un control cuántico separable y conservar el rendimiento de un kernel clásico de función de base radial bajo un presupuesto de entrenamiento restringido.

Las comparaciones principales fueron

Personalizado frente a Separable,

Personalizado frente a ZZ ,

y

Personalizado frente a RBF.

Todavía no podemos afirmar la famosa ventaja cuántica.

5.2. Semillas de muestreo

Utilizamos el conjunto fijo de semillas

$$\mathcal{R} = \{4524, 4525, \dots, 4543\}.$$

Por lo tanto, el número de realizaciones independientes de los subconjuntos fue

$$R = |\mathcal{R}| = 20.$$

Para cada semilla $s \in \mathcal{R}$, sea

$$\mathcal{S}_N^{(s)}$$

el subconjunto balanceado de tamaño N .

5.3. Subconjuntos balanceados y anidados

Para cada semilla s , se extrajeron tres subconjuntos exclusivamente de la partición fija de entrenamiento:

$$\mathcal{S}_{16}^{(s)} \subset \mathcal{S}_{32}^{(s)} \subset \mathcal{S}_{64}^{(s)} \subset \mathcal{D}_{\text{train}}.$$

Cada subconjunto contenía el mismo número de observaciones de ambas clases:

$$\left| \left\{ i \in \mathcal{S}_N^{(s)} : y_i = 0 \right\} \right| = \frac{N}{2},$$

y

$$\left| \left\{ i \in \mathcal{S}_N^{(s)} : y_i = 1 \right\} \right| = \frac{N}{2}.$$

Los tamaños de entrenamiento investigados fueron

$$N \in \{16, 32, 64\}.$$

El diseño anidado nos garantiza que, para una semilla determinada, el aumento del presupuesto de entrenamiento añadiera observaciones sin eliminar las que ya estaban presentes en el subconjunto de menor tamaño.

5.4. Validación cruzada estratificada repetida

Para cada par (s, N) , el rendimiento de los modelos se estimó mediante validación cruzada estratificada repetida.

El diseño utilizó

$$K = 4$$

pliegues y

$$R_{CV} = 5$$

repeticiones.

Por lo tanto, el número de particiones de validación por subconjunto fue

$$L = KR_{CV} = 4 \times 5 = 20.$$

Sean

$$\mathcal{T}_{sNr}$$

y

$$\mathcal{V}_{sNr}$$

las porciones de entrenamiento y validación de la partición r , respectivamente.

Estas satisfacen

$$\mathcal{T}_{sNr} \cap \mathcal{V}_{sNr} = \emptyset,$$

y

$$\mathcal{T}_{sNr} \cup \mathcal{V}_{sNr} = \mathcal{S}_N^{(s)}.$$

Podríamos decir que la estratificación conservó las proporciones de las clases de cada partición.

5.5. Tamaños de los pliegues

Debido a que se utilizó validación cruzada de cuatro pliegues, cada pliegue de validación contenía

$$n_{\text{val}} = \frac{N}{4}$$

observaciones, mientras que cada pliegue de entrenamiento contenía

$$n_{\text{tr}} = \frac{3N}{4}.$$

Por lo tanto,

N	n_{tr}	n_{val}
16	12	4
32	24	8
64	48	16

5.6. Comparación pareada de los modelos

Todos los modelos evaluados bajo una misma combinación

$$(s, N, r)$$

recibieron exactamente los mismos conjuntos

$$\mathcal{T}_{sNr}$$

y

$$\mathcal{V}_{sNr}.$$

Los modelos evaluados fueron

$$\mathcal{M} = \{\text{RBF}, \text{Separable}, \text{ZZ}, \text{ZYY}, \text{Personalizado}\}.$$

Por lo tanto, las diferencias entre los modelos no estuvieron confundidas por el uso de observaciones o particiones de validación cruzada diferentes.

Para los modelos a y b , la diferencia pareada de la métrica Q en cada pliegue fue

$$\Delta_{sNr}^{(a,b)} = Q_{sNr}^{(a)} - Q_{sNr}^{(b)}.$$

5.7. Preprocesamiento dentro de cada partición

Para cada partición r , la media y la desviación estándar de cada variable se estimaron exclusivamente a partir de $\mathcal{T}_{sNr}$:

$$\mu_{j,sNr} = \frac{1}{n_{\text{tr}}} \sum_{i \in \mathcal{T}_{sNr}} x_{ij},$$

y

$$\sigma_{j,sNr} = \sqrt{\frac{1}{n_{\text{tr}} - 1} \sum_{i \in \mathcal{T}_{sNr}} (x_{ij} - \mu_{j,sNr})^2}.$$

Los valores de entrenamiento y validación se transformaron utilizando los mismos estadísticos calculados en el pliegue de entrenamiento:

$$z_{ij,sNr} = \frac{x_{ij} - \mu_{j,sNr}}{\sigma_{j,sNr}}.$$

Para los modelos cuánticos,

$$\theta_{ij,sNr} = \frac{\pi}{2} \tanh(z_{ij,sNr}).$$

Ninguna observación de validación contribuyó al cálculo de

$$\mu_{j,sNr}$$

ni de

$$\sigma_{j,sNr}.$$

5.8. Modelo clásico dentro de cada partición

El modelo clásico se ajustó utilizando la matriz estandarizada de entrenamiento

$$\mathbf{Z}_{\text{tr}}^{(sNr)}$$

y las etiquetas correspondientes

$$\mathbf{y}_{\text{tr}}^{(sNr)}.$$

Su kernel fijo fue

$$K_{\text{RBF}}(\mathbf{z}_i, \mathbf{z}_j) = \exp \left[-\gamma \|\mathbf{z}_i - \mathbf{z}_j\|_2^2 \right],$$

con

$$C = 1, \quad \gamma = \text{scale}, \quad \text{class_weight} = \text{None}.$$

5.9. Modelos cuánticos dentro de cada partición

Para cada mapa cuántico de características m , los estados de entrenamiento se recalcularon dentro de cada partición:

$$|\phi_{i,m}^{(sNr)}\rangle = U_m(\boldsymbol{\theta}_{i,sNr})|0000\rangle.$$

El kernel de entrenamiento fue

$$\left(\mathbf{K}_{m,\text{tr}}^{(sNr)}\right)_{ij} = \left|\left\langle\phi_{j,m}^{(sNr)}\mid\phi_{i,m}^{(sNr)}\right\rangle\right|^2.$$

El kernel entre validación y entrenamiento fue

$$\left(\mathbf{K}_{m,\text{val,tr}}^{(sNr)}\right)_{ij} = \left|\left\langle\phi_{j,m,\text{tr}}^{(sNr)}\mid\phi_{i,m,\text{val}}^{(sNr)}\right\rangle\right|^2.$$

Cada kernel cuántico se proporcionó a un clasificador clásico de vectores de soporte:

$$\text{SVC}(\text{kernel} = \text{precomputed}, C = 1, \text{class_weight} = \text{None}).$$

No se ajustó por separado ningún parámetro del circuito ni hiperparámetro de la SVM para los distintos mapas cuánticos.

5.10. Especificación fijas que utilizamos de los modelos

Las configuraciones fijas de los modelos se resumen en la Tabla 3.

Cuadro 3: Especificaciones fijas utilizadas en el experimento multisevilla.

Modelo	Origen del kernel	C	Configuración adicional
SVM-RBF	RBF gaussiano	1	$\gamma = \text{scale}$
Separable	Fidelidad cuántica	1	Sin compuertas de dos cúbits
ZZ lineal	Fidelidad cuántica	1	Topología lineal ZZ
Pauli $Z + YY$	Fidelidad cuántica	1	Topología lineal YY
Personalizado	Fidelidad cuántica	1	Topología dispersa informada por el dominio

5.11. Número de evaluaciones de los modelos

El número de evaluaciones de modelos a nivel de pliegue fue

$$N_{\text{eval}} = R \times 3 \times L \times 5,$$

donde

$$R = 20$$

es el número de semillas de muestreo,

$$3$$

es el número de tamaños de subconjunto,

$$L = 20$$

es el número de particiones de validación cruzada por subconjunto y

$$5$$

es el número de modelos evaluados.

Por lo tanto,

$$N_{\text{eval}} = 20 \times 3 \times 20 \times 5 = 6000.$$

5.12. Agregación por semilla

Los pliegues de validación cruzada asociados con una misma semilla están correlacionados, debido a que reutilizan observaciones.

Por consiguiente, los pliegues no se consideraron réplicas estadísticas independientes.

Para la métrica Q , la estimación correspondiente a cada semilla fue

$$\overline{Q}_{sN}^{(m)} = \frac{1}{L} \sum_{r=1}^L Q_{sNr}^{(m)}.$$

La muestra estadística final para un tamaño N y un modelo m fijos fue

$$\left\{ \overline{Q}_{sN}^{(m)} : s \in \mathcal{R} \right\},$$

la cual contiene

$$20$$

observaciones.

Por lo tanto, la unidad estadística fue la semilla de muestreo y no cada pliegue individual de validación cruzada.

5.13. Tamaño principal de entrenamiento

La comparación confirmatoria principal se realizó con

$$N = 64.$$

Los presupuestos menores

$$N = 16 \quad \text{y} \quad N = 32$$

se conservaron como análisis de escalamiento y estabilidad.

La selección de los modelos no se basó en resultados aislados de una sola semilla ni de un único tamaño de subconjunto.

5.14. Métrica principal de rendimiento

La métrica principal fue la exactitud balanceada:

$$\text{BA} = \frac{1}{2} (\text{Sensibilidad} + \text{Especificidad}).$$

Por lo tanto, la cantidad principal a nivel de modelo fue

$$\text{mediana}_{s \in \mathcal{R}} \left[\overline{\text{BA}}_{s,64}^{(m)} \right].$$

Las métricas secundarias se utilizaron para la interpretación, pero no para sustituir el criterio principal de selección definido previamente.

5.15. Regla fija de selección del mapa de características

Los mapas cuánticos candidatos se ordenaron mediante la siguiente regla:

- a) mayor mediana de exactitud balanceada para $N = 64$;
- b) un mapa con interacciones entre cúbits debía superar al control separable en la mediana de la diferencia pareada de exactitud balanceada;
- c) los candidatos cuya diferencia fuera menor que

$$\delta_{\text{empate}} = 0.01$$

se consideraron empatados;

- d) el primer criterio de desempate fue la tasa de victorias frente al modelo clásico RBF;
- e) cualquier empate restante se resolvió utilizando el menor número compilado de compuertas de dos cúbits.

Esta regla se fijó antes de examinar los resultados finales del análisis multisevilla.

5.16. Política de la partición de prueba reservada

La partición de prueba

$$\mathcal{D}_{\text{test}}$$

no se utilizó para

- selección de variables;
- diseño del mapa de características;
- selección de circuitos;
- selección de hiperparámetros de la SVM;
- diagnóstico de los kernels cuánticos;
- análisis con un número finito de mediciones;
- selección multisentilla de los modelos;
- desempate basado en recursos.

El conjunto de prueba se reservó para una única evaluación final después de completar la selección del modelo y la validación en Nexus.

En la etapa correspondiente al presente análisis,

$\mathcal{D}_{\text{test}}$ permaneció sin utilizar.

5.17. Controles de reproducibilidad

Se almacenaron los siguientes elementos:

- a)* identificadores ordenados de las muestras de cada subconjunto;
- b)* índices de entrenamiento y validación de cada partición;
- c)* archivos de configuración de los modelos;
- d)* predicciones y métricas de cada pliegue;
- e)* resúmenes por semilla;
- f)* puntos de control parciales de la ejecución;
- g)* valores hash SHA-256 de los elementos fijados;
- h)* tablas de circuitos y recursos compilados.


La semilla original

$$s = 4524$$

se reprodujo exactamente mediante la implementación multisentilla antes de realizar la agregación final.

5.18. Flujo de trabajo experimental

El flujo de trabajo completo para cada pliegue fue



6. Métricas de rendimiento y análisis estadístico

6.1. Matriz de confusión

Para la clase positiva del conjunto de referencia, $y = 1$, la matriz de confusión es

$$\mathbf{C} = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix},$$

donde

TP observaciones con etiqueta potable predichas como potables;

TN observaciones con etiqueta no potable predichas como no potables;

FP observaciones con etiqueta no potable predichas como potables;

FN observaciones con etiqueta potable predichas como no potables.

El número total de observaciones evaluadas es

$$n = TP + TN + FP + FN.$$

6.2. Sensibilidad

La sensibilidad, también denominada exhaustividad de la clase positiva, se define como

$$\text{Sensibilidad} = \text{TPR} = \frac{TP}{TP + FN}.$$

Esta métrica representa la fracción de observaciones con etiqueta de referencia $y = 1$ que se predicen correctamente como 1.

6.3. Especificidad

La especificidad se define como

$$\text{Especificidad} = \text{TNR} = \frac{TN}{TN + FP}.$$

Esta métrica representa la fracción de observaciones con etiqueta de referencia $y = 0$ que se predicen correctamente como 0.

6.4. Tasa de aceptación insegura

La tasa de aceptación insegura se define como la tasa de falsos positivos:

$$\text{UAR} = \text{FPR} = \frac{FP}{FP + TN}.$$

Por lo tanto,

$$\boxed{\text{UAR} = 1 - \text{Especificidad}}$$

Esta métrica tiene un carácter descriptivo. Debido a que la variable objetivo es una etiqueta del conjunto de referencia, la UAR no debe interpretarse como una probabilidad clínica o regulatoria de riesgo para la salud.

6.5. Exactitud balanceada

La exactitud balanceada es la media aritmética de la sensibilidad y la especificidad:

$$\boxed{\text{BA} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right)}$$

o, de manera equivalente,

$$\text{BA} = \frac{\text{TPR} + \text{TNR}}{2}.$$

La exactitud balanceada se utilizó como métrica principal porque asigna el mismo peso a ambas clases.

Un clasificador balanceado no informativo presenta un rendimiento esperado cercano a

$$\text{BA} = 0.5.$$

6.6. Exactitud

La exactitud convencional se define como

$$\text{Exactitud} = \frac{TP + TN}{n}.$$

Esta métrica se reportó para completar el análisis, pero no se utilizó como criterio principal de selección.

6.7. Precisión

La precisión para la clase positiva del conjunto de referencia es

$$\text{Precisin} = \frac{TP}{TP + FP}.$$

Esta métrica representa la fracción de predicciones iguales a 1 que corresponden a observaciones cuya etiqueta de referencia es $y = 1$.

6.8. Puntuación F_1

La puntuación F_1 es la media armónica entre la precisión y la sensibilidad:

$$F_1 = 2 \frac{\text{Precisin} \times \text{Sensibilidad}}{\text{Precisin} + \text{Sensibilidad}}.$$

De manera equivalente,

$$F_1 = \frac{2TP}{2TP + FP + FN}$$

La puntuación F_1 no utiliza explícitamente el número de verdaderos negativos TN , por lo que se trató como una métrica secundaria.

6.9. Coeficiente de correlación de Matthews

El coeficiente de correlación de Matthews se define como

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

con intervalo

$$-1 \leq \text{MCC} \leq 1.$$

Su interpretación es

$MCC = 1 \implies$ clasificación perfecta,

$MCC = 0 \implies$ ausencia de asociación lineal entre las predicciones y las etiquetas,

y

$MCC = -1 \implies$ desacuerdo completo.

Cuando el denominador fue igual a cero, la implementación utilizó la convención finita documentada

$$MCC = 0.$$

6.10. Característica operativa del receptor

Sea

$$f(\mathbf{x})$$

el valor continuo de decisión de la SVM.

Para un umbral t , se define

$$\hat{y}_t = \mathbb{I}[f(\mathbf{x}) \geq t],$$

donde $\mathbb{I}[\cdot]$ es la función indicadora.

La curva característica operativa del receptor se define como

$$ROC(t) = (FPR(t), TPR(t)).$$

El área bajo la curva ROC es

$$AUC = \int_0^1 TPR(FPR^{-1}(u)) du.$$

De manera equivalente, para observaciones $\mathbf{x}^+$ y $\mathbf{x}^-$ seleccionadas aleatoriamente de las clases positiva y negativa, respectivamente,

$$AUC = P[f(\mathbf{x}^+) > f(\mathbf{x}^-)] + \frac{1}{2}P[f(\mathbf{x}^+) = f(\mathbf{x}^-)].$$

El AUC evalúa la capacidad de ordenamiento del modelo, en lugar de la clasificación obtenida con el umbral predeterminado de la SVM.

6.11. Política del AUC para los subconjuntos más pequeños

Para

$$N = 16,$$

cada pliegue de validación contiene únicamente cuatro observaciones.

Por esta razón, el AUC calculado en cada pliegue es altamente discreto e inestable. En consecuencia,

$$\text{AUC}_{N=16}$$

no se utilizó en el resumen final.

El AUC se reportó únicamente para

$$N \in \{32, 64\}.$$

6.12. Métrica agregada por semilla

Sea

$$Q_{sNr}^{(m)}$$

el valor de la métrica Q para el modelo m , la semilla s , el tamaño de subconjunto N y la partición de validación cruzada r .

La estimación correspondiente a cada semilla es

$$\overline{Q}_{sN}^{(m)} = \frac{1}{L} \sum_{r=1}^L Q_{sNr}^{(m)},$$

donde

$$L = 20.$$

Todas las comparaciones inferenciales se realizaron utilizando el conjunto

$$\left\{ \overline{Q}_{sN}^{(m)} \right\}_{s \in \mathcal{R}},$$

en lugar de utilizar individualmente las observaciones correspondientes a cada pliegue.

6.13. Mediana y rango intercuartílico

Para un modelo fijo m y un tamaño de subconjunto N , sea

$$q_s = \overline{Q}_{sN}^{(m)}.$$

La estimación central fue la mediana muestral:

$$\tilde{Q}_N^{(m)} = \text{mediana}_{s \in \mathcal{R}} q_s.$$

El primer y el tercer cuartil se definieron como

$$Q_1 = \text{cuartil}_{0.25}(\{q_s\})$$

y

$$Q_3 = \text{cuartil}_{0.75}(\{q_s\}).$$

El rango intercuartílico es

$$\text{IQR} = Q_3 - Q_1.$$

Los resultados se resumieron como

$$\text{mediana}[Q_1, Q_3].$$

6.14. Diferencia pareada por semilla

Para los modelos a y b , la diferencia pareada correspondiente a la semilla s es

$$d_s^{(a,b)} = \overline{Q}_{sN}^{(a)} - \overline{Q}_{sN}^{(b)}.$$

La estimación principal del efecto es

$$\tilde{\Delta}_N^{(a,b)} = \text{mediana}_{s \in \mathcal{R}} d_s^{(a,b)}.$$

La interpretación es

$$\tilde{\Delta}_N^{(a,b)} > 0 \implies a \text{ tiende a superar a } b,$$

mientras que

$$\tilde{\Delta}_N^{(a,b)} < 0 \implies b \text{ tiende a superar a } a.$$

6.15. Tasas de victoria, empate y derrota

Para una tolerancia numérica

$$\varepsilon = 10^{-12},$$

la tasa de victoria de a frente a b se define como

$$W^{(a,b)} = \frac{1}{R} \sum_{s \in \mathcal{R}} \mathbb{I} [d_s^{(a,b)} > \varepsilon].$$

La tasa de empate se define como

$$T^{(a,b)} = \frac{1}{R} \sum_{s \in \mathcal{R}} \mathbb{I} [|d_s^{(a,b)}| \leq \varepsilon].$$

La tasa de derrota se define como

$$L^{(a,b)} = \frac{1}{R} \sum_{s \in \mathcal{R}} \mathbb{I} [d_s^{(a,b)} < -\varepsilon].$$

Estas cantidades satisfacen

$$W^{(a,b)} + T^{(a,b)} + L^{(a,b)} = 1.$$

6.16. Intervalo bootstrap pareado

Sea

$$\mathbf{d} = \begin{bmatrix} d_1 & d_2 & \cdots & d_R \end{bmatrix}^\top$$

el vector de diferencias pareadas por semilla.

Una muestra bootstrap se construye seleccionando R índices con reemplazo a partir del conjunto

$$\{1, \dots, R\}.$$

Para la repetición bootstrap b ,

$$\tilde{\Delta}^{*(b)} = \text{mediana} \left(d_{i_1^{(b)}}^{(a,b)}, \dots, d_{i_R^{(b)}}^{(a,b)} \right).$$

El número de repeticiones bootstrap fue

$$B = 20000.$$

El intervalo de confianza percentil se definió como

$$\text{IC}_{95\%} = \left[q_{0.025} \left(\tilde{\Delta}^* \right), q_{0.975} \left(\tilde{\Delta}^* \right) \right].$$

El procedimiento bootstrap conservó el carácter pareado del análisis, debido a que las diferencias se remuestrearon por semilla y no independientemente para cada modelo.

6.17. Prueba de rangos con signo de Wilcoxon

La hipótesis nula para la comparación pareada fue

$$H_0 : \text{mediana} \left(d_s^{(a,b)} \right) = 0.$$

La hipótesis alternativa bilateral fue

$$H_1 : \text{mediana} \left(d_s^{(a,b)} \right) \neq 0.$$

Sea

$$r_s$$

el rango de

$$\left| d_s^{(a,b)} \right|$$

después de excluir las diferencias exactamente iguales a cero.

Las sumas de rangos positivos y negativos son

$$W^+ = \sum_{d_s > 0} r_s$$

y

$$W^- = \sum_{d_s < 0} r_s.$$

El estadístico de Wilcoxon es

$$W_{\text{stat}} = \min \left(W^+, W^- \right).$$

La prueba se aplicó a las

$$R = 20$$

diferencias pareadas por semilla.

Los valores p resultantes se interpretaron conjuntamente con

$$\tilde{\Delta}, \quad \text{IC}_{95\%}, \quad W^{(a,b)},$$

en lugar de considerarlos como evidencia aislada.

6.18. Comparaciones estadísticas principales

El análisis principal se realizó para

$$N = 64$$

utilizando la exactitud balanceada.

Los contrastes pareados principales fueron

$$d_s^{(\text{Personalizado, Separable})},$$

$$d_s^{(\text{Personalizado, RBF})},$$

y

$$d_s^{(\text{Personalizado, ZZ})}.$$

Los contrastes adicionales se trataron como análisis complementarios.

6.19. Reglas de interpretación

Se utilizó el siguiente criterio de interpretación.

Si

$$\tilde{\Delta} > 0$$

y el intervalo bootstrap excluye el cero, el resultado se describe como una diferencia pareada positiva y consistente.

Si

$$0 \in \text{IC}_{95\%},$$

el resultado se describe como compatible con paridad entre los modelos o con incertidumbre estadística.

La ausencia de una diferencia detectable no se interpreta como evidencia de que dos modelos sean matemáticamente equivalentes.

6.20. Ausencia de inferencia a nivel de pliegue

Aunque cada modelo generó

$$20$$

puntuaciones de validación cruzada por semilla, estas puntuaciones no son independientes porque sus conjuntos de entrenamiento se superponen.

Por lo tanto, el tamaño muestral inferencial efectivo para un modelo y un tamaño de entrenamiento determinados fue

$$\boxed{R = 20}$$

y no

$$20 \times 20 = 400.$$

Esta restricción evita una inflación artificial de la precisión estadística.

6.21. Jerarquía de métricas

La jerarquía fijada previamente fue

$$\boxed{\text{Exactitud balanceada}}$$

como métrica principal.

Las métricas secundarias fueron

$$\text{MCC}, \quad F_1, \quad \text{AUC}, \quad \text{Especificidad}, \quad \text{UAR}.$$

Las métricas secundarias se utilizaron para evaluar si un cambio en la exactitud balanceada estaba acompañado por un cambio relevante en la capacidad discriminativa o en la distribución de los errores.

7. Resultados multisemilla

7.1. Convención de presentación

Para cada modelo y tamaño de entrenamiento, el valor reportado corresponde a la mediana de las estimaciones obtenidas para las 20 semillas.

La exactitud balanceada se presenta como

$$\widetilde{\text{BA}}[Q_1, Q_3].$$

Las métricas restantes se presentan mediante sus medianas por semilla.

La notación

—

indica que la métrica fue omitida deliberadamente.

7.2. Rendimiento según el tamaño de entrenamiento

La Tabla 4 resume el rendimiento obtenido para

$$N \in \{16, 32, 64\}.$$

Cuadro 4: Rendimiento multisevilla. Los valores corresponden a las medianas de 20 semillas de muestreo. La exactitud balanceada se acompaña de su intervalo intercuartílico.

N	Modelo	BA $[Q_1, Q_3]$	MCC	AUC	Especificidad	UAR
16	RBF	0.556250 [0.471875, 0.612500]	0.122169	–	0.575000	0.425000
16	Separable	0.481250 [0.409375, 0.612500]	–0.035566	–	0.537500	0.462500
16	ZZ lineal	0.537500 [0.471875, 0.606250]	0.090470	–	0.550000	0.450000
16	Pauli $Z + YY$	0.518750 [0.468750, 0.643750]	0.047169	–	0.525000	0.475000
16	Personalizado	0.518750 [0.437500, 0.609375]	0.039434	–	0.562500	0.437500
32	RBF	0.571875 [0.487500, 0.614063]	0.172417	0.615625	0.543750	0.456250
32	Separable	0.459375 [0.448438, 0.487500]	–0.085385	0.484375	0.456250	0.543750
32	ZZ lineal	0.540625 [0.506250, 0.576562]	0.085679	0.565625	0.531250	0.468750
32	Pauli $Z + YY$	0.550000 [0.503125, 0.595312]	0.112479	0.562500	0.531250	0.468750
32	Personalizado	0.521875 [0.493750, 0.593750]	0.048232	0.531250	0.556250	0.443750
64	RBF	0.565625 [0.540625, 0.601562]	0.145838	0.589062	0.609375	0.390625
64	Separable	0.507812 [0.468750, 0.564062]	0.016576	0.530078	0.521875	0.478125
64	ZZ lineal	0.557812 [0.531250, 0.590625]	0.118544	0.572266	0.565625	0.434375
64	Pauli $Z + YY$	0.540625 [0.508594, 0.567188]	0.084581	0.570312	0.562500	0.437500
64	Personalizado	0.560938 [0.528906, 0.603906]	0.126551	0.583984	0.596875	0.403125

7.3. Resultados principales para $N = 64$

El modelo clásico RBF obtuvo la mayor mediana de exactitud balanceada:

$$\widetilde{\text{BA}}_{64}^{(\text{RBF})} = 0.565625.$$

Entre los kernels cuánticos, el mayor valor fue obtenido por el mapa personalizado:

$$\widetilde{\text{BA}}_{64}^{(\text{Personalizado})} = 0.560938.$$

El mapa ZZ lineal obtuvo

$$\widetilde{\text{BA}}_{64}^{(ZZ)} = 0.557812.$$

El control separable obtuvo

$$\widetilde{\text{BA}}_{64}^{(\text{Sep})} = 0.507812.$$

Por lo tanto, el orden según la mediana de exactitud balanceada fue

$$\text{RBF} > \text{Personalizado} > \text{ZZ} > \text{ZYY} > \text{Separable}.$$

7.4. Diferencia de medianas y mediana de las diferencias pareadas

En general,

$$\text{mediana}(A) - \text{mediana}(B) \neq \text{mediana}(A - B).$$

Por ejemplo, la diferencia entre las medianas calculadas por separado para los modelos Personalizado y RBF fue

$$0.560938 - 0.565625 = -0.004687.$$

Sin embargo, la mediana de las diferencias pareadas por semilla fue

$$\tilde{\Delta}_{64}^{(\text{Personalizado}, \text{RBF})} = 0.$$

La cantidad pareada constituye la estimación relevante del efecto, debido a que ambos modelos fueron evaluados sobre los mismos subconjuntos y particiones.

7.5. Comparaciones pareadas para $N = 64$

Los principales resultados pareados se presentan en la Tabla 5.

Cuadro 5: Comparaciones pareadas de exactitud balanceada para $N = 64$. Los intervalos de confianza se obtuvieron mediante bootstrap pareado sobre las 20 semillas de muestreo.

Contraste	Mediana de Δ	IC bootstrap del 95 %	Tasa de victoria	p de Wilcoxon
Personalizado – RBF	0.000000	$[-0.029688, 0.029687]$	0.50	0.925608
ZZ – RBF	-0.001563	$[-0.029688, 0.031250]$	0.50	0.866505
Pauli Z + YY – RBF	-0.021875	$[-0.043750, 0.007812]$	0.30	0.135323
Separable – RBF	-0.042187	$[-0.093750, -0.015625]$	0.20	0.009994
Personalizado – Separable	0.035938	$[0.020312, 0.056250]$	0.80	0.023870
ZZ – Separable	0.046875	$[0.009375, 0.071875]$	0.75	0.011220
Pauli Z + YY – Separable	0.031250	$[0.003125, 0.059375]$	0.70	0.116728

7.6. Mapa personalizado frente al modelo clásico RBF

Para el contraste principal,

$$\widetilde{\Delta}_{64}^{(\text{Personalizado,RBF})} = 0.$$

Su intervalo bootstrap fue

$$\text{IC}_{95\%} = [-0.029688, 0.029687].$$

El intervalo contiene el cero y el mapa personalizado superó al modelo RBF en

$$50\%$$

de las semillas.

Por consiguiente, el resultado observado es compatible con paridad de rendimiento dentro de la resolución del experimento.

Este resultado no demuestra superioridad del mapa personalizado sobre el kernel clásico RBF.

7.7. Mapa personalizado frente al control separable

Para la comparación con el control separable,

$$\widetilde{\Delta}_{64}^{(\text{Personalizado,Sep})} = 0.035938.$$

El intervalo bootstrap fue

$$\text{IC}_{95\%} = [0.020312, 0.056250].$$

El mapa personalizado superó al control separable en

$$80\%$$

de las semillas.

El resultado de la prueba de Wilcoxon fue

$$p = 0.023870.$$

Por lo tanto, el mapa personalizado presentó una diferencia pareada positiva y consistente con respecto al control sin entrelazamiento.

7.8. Mapa ZZZZ lineal frente al control separable

El mapa ZZ lineal obtuvo

$$\widetilde{\Delta}_{64}^{(ZZ, \text{Sep})} = 0.046875,$$

con

$$\text{IC}_{95\%} = [0.009375, 0.071875].$$

Su tasa de victoria fue

$$0.75,$$

y el resultado de la prueba de Wilcoxon fue

$$p = 0.011220.$$

Por consiguiente, las interacciones ZZ genéricas también produjeron una mejora consistente con respecto al control separable.

7.9. Métricas secundarias para $N = 64$

El mapa personalizado obtuvo

$$\text{MCC}_{\text{Personalizado}} = 0.126551$$

y

$$\text{AUC}_{\text{Personalizado}} = 0.583984.$$

Los valores correspondientes al mapa ZZ lineal fueron

$$\text{MCC}_{ZZ} = 0.118544$$

y

$$\text{AUC}_{ZZ} = 0.572266.$$

Por lo tanto, el mapa personalizado presentó valores numéricamente mayores que el mapa ZZ lineal en

$$\text{BA}, \quad \text{MCC}, \quad \text{AUC}.$$

Estas métricas secundarias no se utilizaron para modificar la regla fija de desempate.

7.10. Política de errores

Para $N = 64$, el modelo clásico RBF obtuvo

$$\text{Especificidad}_{\text{RBF}} = 0.609375$$

y

$$\text{UAR}_{\text{RBF}} = 0.390625.$$

El mapa personalizado obtuvo

$$\text{Especificidad}_{\text{Personalizado}} = 0.596875$$

y

$$\text{UAR}_{\text{Personalizado}} = 0.403125.$$

El mapa ZZ lineal obtuvo

$$\text{Especificidad}_{ZZ} = 0.565625$$

y

$$\text{UAR}_{ZZ} = 0.434375.$$

Por lo tanto, el mapa personalizado presentó una política de falsos positivos más conservadora que el mapa ZZ genérico, aunque el modelo RBF mantuvo una especificidad numéricamente superior.

7.11. Comportamiento según el tamaño de entrenamiento

El modelo RBF ocupó la primera posición en los tres tamaños de entrenamiento investigados:

$$N = 16, \quad N = 32, \quad N = 64.$$

La clasificación de los mapas cuánticos varió para los presupuestos más pequeños.

Para

$$N = 16,$$

el mapa ZZ lineal obtuvo la mayor mediana entre los modelos cuánticos.

Para

$$N = 32,$$

el mapa de Pauli $Z + YY$ obtuvo la mayor mediana entre los modelos cuánticos.
Para

$$N = 64,$$

el mapa personalizado obtuvo la mayor mediana entre los modelos cuánticos.

Esta variación indica que las conclusiones basadas en una sola semilla o en un único presupuesto pequeño de entrenamiento serían inestables.

7.12. Aplicación de la regla fija de selección

La mayor mediana entre los mapas con interacciones para $N = 64$ fue

$$\widetilde{\text{BA}}_{64}^{(\text{Personalizado})} = 0.560938.$$

Para el mapa ZZ lineal,

$$\widetilde{\text{BA}}_{64}^{(ZZ)} = 0.557812.$$

Su diferencia absoluta fue

$$|0.560938 - 0.557812| = 0.003126.$$

Debido a que

$$0.003126 < \delta_{\text{empate}} = 0.01,$$

los dos mapas se consideraron empatados según la regla fijada previamente.

Sus tasas de victoria frente al modelo RBF también fueron iguales:

$$W^{(\text{Personalizado}, \text{RBF})} = W^{(ZZ, \text{RBF})} = 0.50.$$

Por consiguiente, la etapa de selección estadística produjo dos modelos cuánticos cofinalistas:

$$\boxed{\mathcal{M}_{\text{final}} = \{\text{Personalizado}, \text{ZZ lineal}\} .}$$

El criterio de desempate restante fue el número compilado de compuertas de dos cúbits.

7.13. Declaración del resultado

El principal resultado empírico es

Personalizado $>$ Separable,
Personalizado $\approx$ RBF,
Personalizado $\sim$ ZZ según la regla fija de selección.

Aquí,

$>$

representa una diferencia pareada positiva y consistente,

$\approx$

representa compatibilidad con paridad de rendimiento, y

$\sim$

representa un empate formal según el procedimiento de selección definido previamente.

7.14. Limitaciones de los resultados

Los resultados no demuestran

- ventaja computacional cuántica;
- superioridad sobre el kernel RBF;
- una determinación regulatoria de la seguridad del agua potable;
- generalización más allá del conjunto de referencia investigado;
- independencia de los resultados con respecto a las cuatro variables seleccionadas.

Los resultados muestran que los mapas de características con interacciones entre múltiples cúbits recuperaron un rendimiento cercano al modelo clásico RBF y superaron al control separable equivalente bajo el protocolo experimental especificado.

8. Robustez frente a un número finito de mediciones

8.1. Estimador del kernel con un número finito de mediciones

Para un par de observaciones i y j , el elemento ideal del kernel de fidelidad es

$$K_{ij} = P_{ij}(0000).$$

Sea

$$S$$

el número de mediciones del circuito, también denominadas *shots*.

Sea

$$C_{ij}^{(0)}$$

el número de mediciones que producen la cadena de bits compuesta únicamente por ceros. Bajo un modelo ideal de muestreo,

$$C_{ij}^{(0)} \sim \text{Binomial}(S, K_{ij}).$$

El estimador con un número finito de mediciones es

$$\widehat{K}_{ij}^{(S)} = \frac{C_{ij}^{(0)}}{S}$$

con valor esperado

$$\mathbb{E} \left[\widehat{K}_{ij}^{(S)} \right] = K_{ij}.$$

Por lo tanto, el estimador es insesgado bajo un modelo ideal de muestreo binomial.

8.2. Varianza de muestreo

La varianza del elemento estimado del kernel es

$$\text{Var} \left[\widehat{K}_{ij}^{(S)} \right] = \frac{K_{ij} (1 - K_{ij})}{S}.$$

Su error estándar es

$$\text{EE} \left[\widehat{K}_{ij}^{(S)} \right] = \sqrt{\frac{K_{ij} (1 - K_{ij})}{S}}.$$

Debido a que

$$K_{ij} (1 - K_{ij}) \leq \frac{1}{4},$$

el error estándar máximo satisface

$$\text{EE} \left[\widehat{K}_{ij}^{(S)} \right] \leq \frac{1}{2\sqrt{S}}.$$

Por lo tanto,

$$\boxed{\text{EE} \propto S^{-1/2}}$$

y multiplicar por cuatro el número de mediciones debería reducir el error de muestreo aproximadamente a la mitad.

8.3. Presupuestos de medición

El mapa personalizado de características se evaluó utilizando

$$S \in \{256, 1024\}.$$

La razón teórica entre los errores es

$$\frac{\text{EE}_{256}}{\text{EE}_{1024}} = \sqrt{\frac{1024}{256}} = 2.$$

Para cada presupuesto de mediciones, el kernel completo correspondiente a $N = 16$ se remuestreó independientemente

$$R_{\text{shot}} = 10$$

veces.

8.4. Perturbación del kernel

Sea

$$\mathbf{K}$$

el kernel exacto y sea

$$\widehat{\mathbf{K}}^{(S,r)}$$

el kernel con un número finito de mediciones para el presupuesto S y la repetición r .

La matriz de perturbación es

$$\mathbf{E}^{(S,r)} = \widehat{\mathbf{K}}^{(S,r)} - \mathbf{K}.$$

8.5. Error absoluto medio

Para un kernel de tamaño $n \times n$, el error absoluto medio de sus elementos es

$$\text{MAE}^{(S,r)} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \left| \widehat{K}_{ij}^{(S,r)} - K_{ij} \right|.$$

Para el presente estudio,

$$n = 16.$$

8.6. Error relativo de Frobenius

La norma de Frobenius se define como

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n A_{ij}^2}.$$

El error relativo del kernel es

$$\varepsilon_F^{(S,r)} = \frac{\left\| \widehat{\mathbf{K}}^{(S,r)} - \mathbf{K} \right\|_F}{\|\mathbf{K}\|_F}.$$

8.7. Correlación del kernel

La correlación lineal entre los elementos exactos y los elementos muestreados es

$$\rho_K^{(S,r)} = \text{corr} \left[\text{vec}(\mathbf{K}), \text{vec} \left(\widehat{\mathbf{K}}^{(S,r)} \right) \right].$$

Un valor cercano a uno indica que se conserva la geometría relativa del kernel.

8.8. Estabilidad espectral

Sea

$$\lambda_{\min}(\mathbf{K})$$

el menor valor propio del kernel exacto.

Para el kernel exacto del mapa personalizado con $N = 16$,

$$\lambda_{\min}(\mathbf{K}) = 0.116566.$$

Para cada kernel muestreado, la estabilidad espectral se evaluó mediante

$$\lambda_{\min} \left(\widehat{\mathbf{K}}^{(S,r)} \right).$$

Un kernel muestreado se consideró semidefinido positivo cuando

$$\lambda_{\min} \left(\widehat{\mathbf{K}}^{(S,r)} \right) \geq -\varepsilon_{\text{PSD}},$$

donde ε_{PSD} es una tolerancia numérica.

En general, el muestreo con un número finito de mediciones no garantiza la semi-definitud positiva. Por lo tanto, la conservación de esta propiedad es un resultado empírico del presente experimento y no una característica universal.

8.9. Resultados a nivel del kernel

La Tabla 6 presenta las medianas de los errores con un número finito de mediciones, calculadas sobre diez repeticiones independientes.

Cuadro 6: Perturbación del kernel personalizado para $N = 16$ bajo un número finito de mediciones. Los valores corresponden a las medianas de diez repeticiones de remuestreo.

Mediciones	MAE	Error relativo de Frobenius	Correlación	$\lambda_{\min}$	Tasa PSD
256	0.016604	0.062176	0.997019	0.080933	1.00
1024	0.008498	0.032069	0.999207	0.114352	1.00

8.10. Incertidumbre intercuartílica

Para 256 mediciones, la distribución del MAE fue

$$0.016604 [0.015872, 0.018272].$$

El error relativo de Frobenius fue

$$0.062176 [0.058778, 0.067767].$$

Para 1024 mediciones, la distribución del MAE fue

$$0.008498 [0.007841, 0.008682],$$

y el error relativo de Frobenius fue

$$0.032069 [0.030025, 0.032795].$$

8.11. Escalamiento observado con el número de mediciones

La razón empírica entre los valores medianos del MAE fue

$$\frac{\text{mediana}(\text{MAE}_{256})}{\text{mediana}(\text{MAE}_{1024})} = \frac{0.016604}{0.008498} = 1.9539.$$

Este valor es cercano a la razón teórica

$$2.$$

Por lo tanto,

$$\boxed{\text{error observado del kernel} \approx S^{-1/2}}$$

bajo un modelo ideal de muestreo binomial.

8.12. Error máximo por elemento

Las medianas de los errores absolutos máximos por elemento fueron

$$\text{mediana} \left[\max_{ij} \left| E_{ij}^{(256)} \right| \right] = 0.075254$$

y

$$\text{mediana} \left[\max_{ij} \left| E_{ij}^{(1024)} \right| \right] = 0.038671.$$

Por lo tanto, las mayores perturbaciones individuales también se redujeron aproximadamente a la mitad cuando el número de mediciones aumentó por un factor de cuatro.

8.13. Experimento de clasificación posterior

La similitud entre kernels no garantiza que las decisiones de la SVM sean idénticas. Por esta razón, los kernels muestreados también se propagaron a través del procedimiento completo de clasificación.

Para cada partición de validación cruzada, el clasificador exacto utilizó

$$\mathbf{K}_{\text{tr}}$$

y

$$\mathbf{K}_{\text{val, tr}},$$

mientras que el clasificador con un número finito de mediciones utilizó

$$\widehat{\mathbf{K}}_{\text{tr}}^{(S,r)}$$

y

$$\widehat{\mathbf{K}}_{\text{val,tr}}^{(S,r)}.$$

La especificación de la SVM se mantuvo fija:

$$C = 1, \quad \text{kernel} = \text{precomputed}.$$

8.14. Tasa de cambio de las predicciones

Sean

$$\widehat{y}_{i,\text{exacto}}$$

y

$$\widehat{y}_{i,S,r}$$

las predicciones obtenidas con el kernel exacto y el kernel muestreado, respectivamente.

La tasa de cambio de las predicciones se define como

$$R_{\text{cambio}}^{(S,r)} = \frac{1}{n_{\text{pred}}} \sum_{i=1}^{n_{\text{pred}}} \mathbb{I}[\widehat{y}_{i,S,r} \neq \widehat{y}_{i,\text{exacto}}].$$

8.15. Resultados posteriores de clasificación

El modelo personalizado exacto para $N = 16$ obtuvo

$$\text{BA}_{\text{exacta}} = 0.512500.$$

Los resultados obtenidos con un número finito de mediciones se presentan en la Tabla 7.

Cuadro 7: Clasificación posterior bajo muestreo del kernel con un número finito de mediciones. Los valores corresponden a las medianas de diez repeticiones.

Mediciones	BA	ΔBA	MCC	Cambio de predicción	Tasa PSD
256	0.518750	0.006250	0.039434	0.062500	1.00
1024	0.525000	0.012500	0.050000	0.031250	1.00

8.16. Estabilidad de las decisiones

Con 256 mediciones, el kernel muestreado modificó aproximadamente el

$$6.25 \%$$

de las predicciones obtenidas con el kernel exacto.

Con 1024 mediciones, la tasa de cambio de las predicciones disminuyó a

$$3.125 \%.$$

Por lo tanto, aumentar el número de mediciones de 256 a 1024 redujo aproximadamente a la mitad tanto

el error de los elementos del kernel

como

la perturbación de las predicciones.

8.17. Aumento aparente de la exactitud balanceada

Los modelos muestreados produjeron pequeñas diferencias medianas positivas con respecto al modelo exacto:

$$\Delta BA_{256} = 0.006250$$

y

$$\Delta BA_{1024} = 0.012500.$$

Estos valores no se interpretan como una mejora causada por el ruido de muestreo.

Los pliegues de validación para $N = 16$ contienen únicamente cuatro observaciones, por lo que la exactitud balanceada cambia en incrementos discretos relativamente grandes. En consecuencia, una cantidad pequeña de predicciones modificadas puede producir un cambio aparentemente positivo o negativo.

La conclusión válida es la estabilidad del modelo y no un aprendizaje favorecido por el ruido.

8.18. Especificidad con un número finito de mediciones

Las medianas de especificidad fueron

$$\text{Especificidad}_{256} = 0.600000$$

y

$$\text{Especificidad}_{1024} = 0.587500.$$

Las tasas de aceptación insegura correspondientes fueron

$$\text{UAR}_{256} = 0.400000$$

y

$$\text{UAR}_{1024} = 0.412500.$$

Por lo tanto, las perturbaciones producidas por un número finito de mediciones no mejoraron la política de errores orientada a la seguridad, a pesar de los pequeños cambios positivos en la exactitud balanceada.

8.19. Declaración del resultado con un número finito de mediciones

El principal resultado del análisis es

$S : 256 \longrightarrow 1024,$
$\text{MAE} : 0.016604 \longrightarrow 0.008498,$
$\varepsilon_F : 0.062176 \longrightarrow 0.032069,$
$R_{\text{cambio}} : 0.062500 \longrightarrow 0.031250.$

Un aumento de cuatro veces en el número de mediciones redujo aproximadamente a la mitad la perturbación del kernel y la proporción de predicciones modificadas.

8.20. Alcance del análisis con un número finito de mediciones

El experimento representa el ruido ideal de medición mediante muestreo binomial.

No incluye

- errores de preparación del estado;
- errores coherentes de compuertas;
- decoherencia;
- errores de asignación de las mediciones;

- deriva de la calibración;
- diafonía;
- efectos de compilación específicos del dispositivo.

Estos efectos requieren validación mediante el emulador de Quantinuum H2 o hardware cuántico.

9. Compilación para Quantinuum H2

9.1. Propósito de la compilación

La estructura lógica de un circuito no determina directamente su costo en hardware. Un operador lógico de dos cúbits puede requerir varias operaciones nativas después de los procesos de

descomposición de compuertas, optimización, enrutamiento,

y

traducción al conjunto de compuertas objetivo.

Por lo tanto, la comparación de recursos se realizó después de compilar los circuitos a un conjunto de compuertas compatible con H2.

Los dos mapas cuánticos seleccionados estadísticamente fueron

$$\mathcal{M}_{\text{final}} = \{\text{Personalizado}, \text{ZZ lineal}\}.$$

9.2. Flujo de compilación

Para cada circuito numérico de solapamiento, el flujo de trabajo fue

circuito de Qiskit $\longrightarrow$ circuito de TKET $\longrightarrow$ compilación compatible con H2 $\longrightarrow$ auditoría de recursos

Los parámetros del circuito se sustituyeron por valores numéricos antes de realizar la conversión.

La clase objetivo de interacción entre dos cúbits fue

ZZPhase.

La compilación utilizó

`optimization_level = 2.`

9.3. Circuitos de solapamiento con parámetros numéricos

Para las observaciones i y j , el circuito de solapamiento fue

$$V_{ij}^{(m)} = U_m^\dagger(\boldsymbol{\theta}_j) U_m(\boldsymbol{\theta}_i),$$

donde

$$m \in \{\text{Personalizado}, \text{ZZ}\}.$$

Todos los ángulos simbólicos se sustituyeron por sus valores numéricos antes de realizar la conversión de Qiskit a TKET.

Esto evitó ambigüedades en la traducción de parámetros simbólicos y permitió realizar pruebas directas de equivalencia numérica.

9.4. Conjunto de circuitos compilados

El subconjunto con $N = 16$ contiene

$$\frac{16(16-1)}{2} = 120$$

pares únicos fuera de la diagonal.

Para cada mapa de características se compilaron

$$N_{\text{pares}} = 120$$

circuitos de solapamiento.

Los elementos de la diagonal satisfacen

$$K_{ii} = 1$$

en el kernel ideal, por lo que se excluyeron de la comparación principal de recursos compilados.

9.5. Cantidades de recursos

Para el circuito compilado c , se define

$$G_2(c)$$

como el número de compuertas compiladas de dos cúbits,

$$D_2(c)$$

como la profundidad de compuertas de dos cúbits,

$$G_1(c)$$

como el número de compuertas compiladas de un cúbit, y

$$G_{\text{tot}}(c) = G_1(c) + G_2(c)$$

como el número total de compuertas.

Para el mapa de características m , el número total de compuertas de dos cúbits es

$$G_{2,\text{suma}}^{(m)} = \sum_{c=1}^{120} G_2^{(m)}(c).$$

La mediana del número de compuertas de dos cúbits es

$$\tilde{G}_2^{(m)} = \text{mediana}_c G_2^{(m)}(c).$$

La mediana de la profundidad de compuertas de dos cúbits es

$$\tilde{D}_2^{(m)} = \text{mediana}_c D_2^{(m)}(c).$$

9.6. Resultados de recursos de dos cúbits

Ambos cofinalistas requirieron

$$G_2^{(m)}(c) = 5$$

compuertas compiladas de dos cúbits para cada circuito de solapamiento evaluado.

Por lo tanto,

$$G_{2,\text{suma}}^{(\text{Personalizado})} = 120 \times 5 = 600$$

y

$$G_{2,\text{suma}}^{(\text{ZZ})} = 120 \times 5 = 600.$$

Para ambos mapas,

$$\tilde{G}_2 = 5,$$

$$G_{2,\text{mín}} = 5,$$

$$G_{2,\text{máx}} = 5,$$

y

$$\tilde{D}_2 = 5.$$

9.7. Resultados de compuertas de un cúbit y compuertas totales

Los circuitos del mapa personalizado requirieron

$$G_{1,\text{suma}}^{(\text{Personalizado})} = 1820$$

compuertas compiladas de un cúbit.

Los circuitos del mapa ZZ lineal requirieron

$$G_{1,\text{suma}}^{(ZZ)} = 1848.$$

Por lo tanto, sus números totales de compuertas compiladas fueron

$$G_{\text{tot,suma}}^{(\text{Personalizado})} = 1820 + 600 = 2420$$

y

$$G_{\text{tot,suma}}^{(ZZ)} = 1848 + 600 = 2448.$$

La diferencia absoluta en el número total de compuertas fue

$$2448 - 2420 = 28.$$

La reducción relativa del mapa personalizado fue

$$\frac{2448 - 2420}{2448} \times 100 = 1.14 \%.$$

9.8. Tabla de recursos compilados

Cuadro 8: Recursos compilados localmente y compatibles con H2 para los dos cofinalistas cuánticos. Los resultados incluyen los 120 solapamientos únicos fuera de la diagonal del subconjunto con $N = 16$.

Mapa	Pares	Total 2Q	Mediana 2Q	Mín.–máx. 2Q	Profundidad 2Q	Total 1Q	Compuertas totales
Personalizado	120	600	5	5 – –5	5	1820	2420
ZZ lineal	120	600	5	5 – –5	5	1848	2448

9.9. Equivalencia posterior a la compilación

La compilación debe conservar la acción numérica del circuito original.

Sea

$$\varepsilon_{\text{eq}}(c)$$

el error de equivalencia numérica, insensible a la fase global, entre el circuito original y su representación compilada.

El mayor error observado entre ambos mapas y todos los circuitos compilados fue

$$\boxed{\varepsilon_{\text{eq,max}} = 7.605 \times 10^{-15}}$$

lo cual es compatible con la precisión de punto flotante.

Por lo tanto, no se detectó ningún cambio material en la transformación cuántica implementada después de la compilación.

9.10. Criterio de desempate basado en recursos

La regla fija de selección estableció el número compilado de compuertas de dos cúbits como criterio final de desempate.

Sin embargo,

$$G_{2,\text{suma}}^{(\text{Personalizado})} = G_{2,\text{suma}}^{(\text{ZZ})},$$

$$\tilde{G}_2^{(\text{Personalizado})} = \tilde{G}_2^{(\text{ZZ})},$$

y

$$\tilde{D}_2^{(\text{Personalizado})} = \tilde{D}_2^{(\text{ZZ})}.$$

Por lo tanto, la compilación local no resolvió el empate formal.

La diferencia en el número de compuertas de un cúbit no se utilizó como un criterio de desempate alternativo definido posteriormente.

9.11. Relación entre rendimiento y recursos

Para $N = 64$, las medianas por semilla fueron

$$\widetilde{\text{BA}}_{\text{Personalizado}} = 0.560938$$

y

$$\widetilde{\text{BA}}_{\text{ZZ}} = 0.557812.$$

Sus costos compilados de dos cúbits fueron iguales:

$$\tilde{G}_{2,\text{Personalizado}} = \tilde{G}_{2,\text{ZZ}} = 5.$$

Por lo tanto, el mapa personalizado obtuvo valores numéricamente mayores de

$$\text{BA}, \quad \text{MCC}, \quad \text{AUC},$$

sin incrementar el recurso compilado dominante de dos cúbits.

Esta comparación es descriptiva y no modifica el empate formal establecido por la regla fija de selección.

9.12. Interpretación

Los resultados de la compilación local establecen tres puntos.

Primero,

el mapa personalizado no requiere más compuertas compiladas 2Q que el mapa ZZ lineal.

Segundo,

ambos mapas presentan la misma profundidad compilada 2Q.

Tercero,

el mapa personalizado es ligeramente más compacto en compuertas 1Q y en compuertas totales.

El tercer resultado es secundario, debido a que el número de compuertas de un cúbit no formaba parte del criterio final de desempate definido previamente.

9.13. Estado actual de la selección

El estado formal después de la compilación local es

$$\boxed{\text{LOCAL_COMPILE_TIE_REQUIRES_NEXUS_CONFIRMATION}}$$

Por consiguiente,

$$\boxed{\mathcal{M}_{\text{final}} = \{\text{Personalizado}, \text{ZZ lineal}\}.$$

El mapa personalizado se mantiene como la arquitectura propuesta informada por el dominio.

El mapa ZZ lineal se mantiene como el cofinalista genérico con recursos equivalentes.

9.14. Alcance de los resultados de compilación

El presente análisis utilizó compilación local con un objetivo compatible con H2.

Todavía no establece

- los resultados de la compilación remota mediante Nexus;
- el costo de espera o ejecución;
- los efectos de calibración del dispositivo;
- la fidelidad del kernel en el emulador H2;
- las distribuciones de medición del hardware;
- el rendimiento de clasificación en un dispositivo cuántico real.

Estas cantidades se reservan para la etapa de validación mediante Nexus.